

SED Model za Detekciju Okidača Mizofonije

1. Definicija Problema

1.1. Mizofonija

Mizofonija je poremećaj koji izaziva abnormalnu osetljivost na određene zvukove. Ovi zvukovi se obično nazivaju "okidači" i izazivaju jaku negativnu emocionalnu i psihološku reakciju, najčešće bes, nervozu, gađenje, anksioznost, paniku, kao i fiziološku autonomnu reakciju (lupanje srca, ubrzano disanje, znojenje, mučnina i slično). Ljudi koji pate od mizofonije imaju različite okidače, ali to su najčešće zvukovi koje proizvode ljudi, kao na primer žvakanje, disanje, gutanje, kašalj. Poremećaj postoji na spektrumu, gde veliki procenat populacije (do 68%) doživljava simptome koji su ispod kliničkog praga. Kod manjeg procenta ljudi, simptomi imaju veoma negativan uticaj na život i mentalno zdravlje zbog opšte-prisutnosti okidačkih zvukova: u jednom istraživanju, više od 20% ispitanika koji pate od mizofonije je prijavilo suicidalne misli.

Za ovaj projekat važno je pomenuti da terapija izlaganjem nije dokazana i u nekim slučajevima čak ima negativne efekte. Sa druge strane, umereno izbegavanje okidača ne deluje kao da ima negativne efekte na sposobnost mizofoničnih ljudi da se nose sa poremećajem.

1.2. Model

Ovaj model je zamišljen kao pomoć pri gledanju filmova, serija i ostalih videa time što bi anotirao intervale gde se pojavljuju neželjeni zvukovi, i tako smanjio anksioznost i upozorio korisnika da te intervale utiša. Specifično bi se fokusirao samo na zvuk žvakanja, zato što je to najčešći okidač kod mizofoničnih ljudi i takođe okidač koji se najčešće pojavljuje.

Postojeća slična rešenja su pokušala da naprave model koji bi zvukove klasifikovao u realnom vremenu za eventualno utišavanje sa specijalnim slušalicama, ili uopšte nisu pokušavala praktičnu primenu. Anotiranje videa je izvodljivije jer nema potrebu za izvršavanjem u realnom vremenu i time može da postigne bolju tačnost. Takođe, nema potrebe za posebnim hardverom osim GPU kartice.

2. Skup Podataka

Nažalost, postoji relativno malo gotovih skupova podataka koji su direktno fokusirani na ovu temu. Koliko ja vidim, ovo je sve što je dostupno:

- AudioSet kategorija [Chewing, mastication](#), 2+ sata materijala.
- [Free Open-Access Misophonia Stimuli](#), manje, *strongly-labeled* audio materijala.
- [Misophonia Audiovisual Trigger Archive](#).
- [Eating Sound Collection](#), puno audio materijala, snimljeno u studiu.

Ostatak podataka će se skupiti sa Youtube-a i iz filmova i serija. *Eating Sound Collection* se može koristiti za sintezu realnijih snimaka uz kombinaciju sa nekim pozadinskim zvukom i varijacijama u jačini zvuka, *reverb*-u, itd.

3. Metodologija

Plan je da se napravi model koji bi anotirao video snimke. Ovo bi se postiglo tako što se od unesenog videa (ili dela videa) napravi lista verovatnoća (tj. sigurnosti modela) po segmentima, koja bi se onda kroz *Browser* ekstenziju ili specijalni video plejer pretvorila u jedno dimenzionalni *heat-map*. Radi demonstracije, napraviću jednostavan video plejer i python server koji prihvata video i vraća predikcije.

Najosnovnija verzija modela bi se zasnivala na *pretrained CNN feature-extractor* delu sa priključenom RNN glavom, koji se trenira koristeći mel-spektrograme audio materijala. Ovu tehniku su koristili drugi projekti na ovu temu.

Važno je napomenuti da mizofonija nije prosto auditorni poremećaj već postoji na višem nivou razmišljanja, tj. izvor zvuka je bitan. Kod većine mizofoničnih ljudi zvukovi koji bi inače bili okidači nemaju efekta kada ih proizvode životinje ili oni sami. Takođe, postoje zvuci koji su veoma slični žvakanju (na primer, šetanje u nekim starim filmovima) ali ne proizvode mizofonične reakcije. Stoga, dodatak još jedne *feature-extractor* komponente koja radi sa vizuelnim delom videa bi značajno unapredila stopu lažnih pozitiva, ali bi njena implementacija možda zahtevala previše računarskih resursa za pokretanje i potencijalno bila van njihovih sposobnosti.

Pretrained Transformer model bi se takođe mogao iskoristiti za *feature* ekstrakciju, ali snosi isti problem brzine kao i video model, uz mogućnost da ne daje mnogo bolje performanse. U svakom slučaju bi se ta arhitektura trebala testirati i porediti sa CNN modelom.

Ove dve sugestije nisu zagarantovane i nadam se da će prva dva paragrafa biti dovoljana za projekat, iz prostog razloga što ne mogu da znam koliko je ovo teško za implementaciju pre nego što počnem.

4. Način evaluacije

Za evaluaciju ću se najviše fokusirati na AUPRC krivu nad ručno anotiranim epizodama serija i filmovima. Pored ovoga ću koristiti event-wise evaluacije kao F1 score.

5. Tehnologija

Za implementaciju modela koristiću Python i PyTorch, uz torchaudio za obradu zvuka i generisanje mel-spektrograma. Demonstracioni sistem bi se sastojao od jednostavnog Python servera, koristeći Flask, i video plejera napravljenog u Electron-u.

6. Primeri

[Misophonia Trigger Sound Detection on Synthetic Soundscapes Using a Hybrid Model with a Frozen Pre-Trained CNN and a Time-Series Module, Kurumi Sashida and Gouhei Tanaka](#)

[Selective noise cancelling application for misophonia treatment, Timothy Wunrow](#)

[Misophonia Sound Recognition Using PaSST, Charlotte Marosvölgyi](#)

7. Relevantna Literatura

[Toward cognitive models of misophonia, Marie-Anick Savard and Emily B.J. Coffey](#)

PANNs: Large-Scale Pretrained Audio Neural Networks for Audio Pattern Recognition, Qiuqiang Kong, Yin Cao, Turab Iqbal, Yuxuan Wang, Wenwu Wang and Mark D. Plumbley

Multi-Iteration Multi-Stage Fine-Tuning of Transformers for Sound Event Detection with Heterogeneous Datasets, Florian Schmid, Paul Primus, Tobias Morocutti, Jonathan Greif and Gerhard Widmer